



FACULTAD DE CIENCIAS
CARRERA DE INGENIERÍA MATEMÁTICA

PLAN DE TRABAJO DE TITULACIÓN

TIPO DE TRABAJO DE TITULACIÓN: PROYECTO DE INVESTIGACIÓN

I.- INFORMACIÓN BÁSICA

PROPUESTO POR:

Geoconda Dennisse Molina Morales

LÍNEA DE INVESTIGACIÓN:

Modelos Estadísticos

AUSPICIADO POR:

PhD. Méthor Oswaldo Urvina Mayorga

FECHA:

23/02/2024

II.- INFORMACIÓN DEL TRABAJO DE TITULACIÓN

1. Título del Trabajo de Titulación

APLICACIONES DE LAS TÉCNICAS DE OPTIMIZACIÓN ESTADÍSTICA ENFOCADA A LA COMPUTACIÓN GRÁFICA

2. Planteamiento del Problema

En el ámbito de las matemáticas, la aplicación de técnicas de optimización y modelos estadísticos en la computación gráfica plantea desafíos significativos. Si bien estos métodos ofrecen un marco teórico sólido, su implementación práctica en entornos gráficos presenta dificultades específicas. La falta de integración efectiva entre los conceptos estadísticos y los sistemas de procesamiento de imágenes limita el potencial de mejorar la precisión y la eficiencia en la generación y manipulación de datos visuales.

Una de las problemáticas adicionales radica en la falta de participación de muchos matemáticos en el campo de la computación gráfica. Esta brecha impide aprovechar plenamente el conocimiento y la experiencia de los expertos en matemáticas en la resolución de problemas complejos en este ámbito. Es crucial fomentar una mayor colaboración e interacción entre los matemáticos y los profesionales de la computación gráfica para impulsar la innovación y el progreso en esta área.

Además, otra problemática relevante es la escasez de proyectos que utilicen agentes q-learning en el contexto de la computación gráfica, especialmente en regiones como el Ecuador. La falta de investigación y desarrollo en este campo limita las oportunidades de aplicar y evaluar estas técnicas en entornos gráficos específicos, lo que a su vez restringe el avance y la adopción de nuevas metodologías y enfoques.

El propósito de esta investigación es explorar cómo superar estas dificultades desde una perspectiva matemática. Esto implica desarrollar nuevas metodologías y enfoques que permitan una integración más fluida de técnicas estadísticas en la computación gráfica, así como promover una mayor participación de los matemáticos en este campo. Al abordar estas



problemáticas desde una perspectiva matemática, se puede avanzar hacia soluciones más robustas y eficientes, contribuyendo así al desarrollo y la innovación en el campo de la.

3. Justificación

2.1 Justificación Teórica

La presente investigación se enmarca en el cruce entre la teoría matemática y la computación gráfica, dos campos interdisciplinarios que han ganado relevancia en la era digital. Desde una perspectiva teórica, este estudio se basa en las sólidas fundamentaciones de la teoría del aprendizaje por refuerzo y las redes neuronales convolucionales (CNN, por sus siglas en inglés). Según el matemático Richard S. Sutton, uno de los pioneros en el campo del aprendizaje por refuerzo, "el aprendizaje por refuerzo trata del objetivo de aprender a tomar decisiones, tomar buenas decisiones, o, más generalmente, interactuar con el entorno" (Sutton & Barto, 1998).

Al integrar el agente q-learning con las CNN, este estudio busca llenar las lagunas existentes en la teoría al explorar una nueva perspectiva en la aplicación de estas técnicas en el campo de la computación gráfica. Como apunta David J. Fleet, experto en visión por computadora, "las redes neuronales convolucionales han demostrado ser extremadamente eficaces para el procesamiento de imágenes y la extracción de características relevantes" (Fleet & Hertzmann, 2006). La combinación de la teoría del aprendizaje por refuerzo con el procesamiento de imágenes a través de redes neuronales convolucionales representa un avance significativo en la comprensión de cómo los sistemas pueden aprender de manera autónoma y realizar tareas complejas en entornos visuales.

2.2 Justificación Metodológica.

La metodología propuesta para esta investigación implica un enfoque integral que combina el diseño e implementación de un agente q-learning con la integración de redes neuronales convolucionales (CNN) para el procesamiento de imágenes. Esta metodología se desarrollará en varias etapas para asegurar la rigurosidad del estudio y la obtención de resultados significativos.

En primer lugar, se llevará a cabo un proceso de diseño detallado del agente q-learning, definiendo sus parámetros, estructura y algoritmos de aprendizaje. Se seleccionarán las bibliotecas y herramientas de programación adecuadas en Python para facilitar la implementación del agente y su integración con las redes neuronales convolucionales.

Una vez que el agente q-learning esté diseñado e implementado, se procederá a la fase de recolección de datos. Esta etapa implicará la interacción del agente con un entorno virtual diseñado específicamente para este estudio. Se generarán diferentes escenarios y tareas dentro del entorno gráfico, permitiendo al agente experimentar y aprender de su entorno a través de la retroalimentación de recompensas.

La recopilación de datos se llevará a cabo mediante la observación y registro de las acciones y decisiones tomadas por el agente durante su proceso de aprendizaje. Se registrarán datos como las imágenes de entrada, las acciones tomadas por el agente en respuesta a estas imágenes, y las recompensas recibidas. Este enfoque garantizará la captura de información relevante para evaluar el desempeño del agente y analizar su capacidad de aprendizaje en un entorno gráfico.



Posteriormente, se procederá a la fase de análisis de datos, donde se evaluará el rendimiento del agente en la realización de diversas actividades dentro del entorno gráfico. Se examinará cómo la incorporación de las redes neuronales convolucionales afecta la capacidad de aprendizaje y ejecución de tareas del agente. Se emplearán métricas y técnicas de evaluación estándar, como la precisión, el tiempo de ejecución y la eficacia del agente en la resolución de problemas gráficos.

2.3 Justificación Práctica

La relevancia práctica de esta investigación radica en su capacidad para demostrar el potencial de los agentes q-learning con redes neuronales convolucionales en la realización de tareas dentro del ámbito de la computación gráfica. Los beneficiarios potenciales de este estudio incluyen a profesionales y desarrolladores de software en campos como la animación, el diseño gráfico, la realidad virtual y aumentada, así como también a la sociedad en general, que se beneficiaría de tecnologías más avanzadas y eficientes en la representación y manipulación de imágenes digitales.

Los resultados de esta investigación pueden tener un impacto significativo en la resolución de problemas prácticos en la industria y en el desarrollo de nuevas aplicaciones y herramientas en el campo de la computación gráfica. Además, al demostrar cómo los matemáticos pueden contribuir al mundo del arte gráfico a través de la implementación de técnicas avanzadas de aprendizaje automático, este estudio también puede fomentar una mayor participación de expertos en matemáticas en áreas interdisciplinarias, promoviendo así la colaboración y la innovación en la ciencia y la tecnología.



4. Objetivo General

Investigar y desarrollar un agente q-learning que incorpore redes neuronales convolucionales para la realización de tareas en entornos gráficos, con el fin de demostrar cómo los matemáticos pueden contribuir al mundo del arte gráfico y la computación gráfica, destacando el papel crucial de la optimización estadística aportada por los matemáticos en el desarrollo de inteligencias artificiales, específicamente en el campo del deep learning, con el fin de demostrar su relevancia en la mejora de la eficiencia y precisión en la resolución de problemas prácticos.

5. Objetivos Específicos

- *Diseñar y desarrollar un agente q-learning que integre redes neuronales convolucionales, con un énfasis en la aplicación de técnicas de optimización estadística por parte de los matemáticos para mejorar su desempeño en entornos gráficos.*
- *Implementar redes neuronales convolucionales en el agente q-learning, enfocándose en la utilización de métodos de optimización.*
- *Crear un entorno virtual que permita al agente realizar diversas tareas en el ámbito de la computación gráfica.*
- *Recopilar datos mediante la observación y registro de las acciones y decisiones tomadas por el agente durante su proceso de aprendizaje en el entorno gráfico.*
- *Evaluar el rendimiento del agente q-learning en la realización de actividades dentro del entorno gráfico, utilizando métricas y técnicas de evaluación estándar, así como métodos de optimización estadística para mejorar su eficiencia y precisión en la toma de decisiones.*
- *Analizar cómo la integración de redes neuronales convolucionales y técnicas de optimización estadística influye en la capacidad de aprendizaje y ejecución de tareas del agente en entornos gráficos, identificando las mejoras significativas en términos de eficiencia y precisión.*
- *Documentar y presentar los resultados obtenidos de manera clara y precisa, destacando el papel fundamental de las técnicas de optimización estadística en el desarrollo de inteligencias artificiales, especialmente en el campo del deep learning.*
- *Promover la importancia de la colaboración entre matemáticos y expertos en inteligencia artificial en el desarrollo de tecnologías avanzadas, resaltando el valor añadido de la optimización estadística en el campo del deep learning.*
- *Proporcionar recomendaciones y líneas de investigación futuras para seguir explorando el potencial de los agentes q-learning con redes neuronales convolucionales y técnicas de optimización estadística en entornos gráficos, con el*



objetivo de avanzar en la mejora de la eficiencia y precisión en la computación gráfica y la inteligencia artificial

6. Metodología

- 1. Diseñar y desarrollar un agente q-learning que integre redes neuronales convolucionales, con un énfasis en la aplicación de técnicas de optimización estadísticas.*
- 2. Implementar redes neuronales convolucionales en el agente q-learning, enfocándose en la utilización de métodos de optimización estadística para optimizar la arquitectura y los parámetros del modelo, con el objetivo de mejorar la eficiencia y precisión en el procesamiento de imágenes.*
- 3. Crear un entorno virtual que permita al agente realizar diversas tareas en el ámbito de la computación gráfica.*
- 4. Recopilar datos mediante la observación y registro de las acciones y decisiones tomadas por el agente durante su proceso de aprendizaje en el entorno gráfico, haciendo énfasis en el análisis del impacto de las técnicas de optimización estadística en su desempeño y capacidad de adaptación.*
- 5. Evaluar el rendimiento del agente q-learning en la realización de actividades dentro del entorno gráfico, utilizando métricas y técnicas de evaluación estándar, así como métodos de optimización estadística.*
- 6. Analizar cómo la integración de redes neuronales convolucionales y técnicas de optimización estadística influye en la capacidad de aprendizaje y ejecución de tareas del agente en entornos gráficos, identificando las mejoras significativas en términos de eficiencia y precisión.*
- 7. Documentar y presentar los resultados obtenidos de manera clara y precisa, destacando el papel fundamental de las técnicas de optimización estadística en el desarrollo de inteligencias artificiales, especialmente en el campo del deep learning, para mejorar la eficiencia y precisión en la resolución de problemas prácticos.*
- 8. Promover la importancia de la colaboración entre matemáticos y expertos en inteligencia artificial en el desarrollo de tecnologías avanzadas, resaltando el valor añadido de la optimización estadística en el campo del deep learning.*



9. *Proporcionar recomendaciones y líneas de investigación futuras para seguir explorando el potencial de los agentes q-learning con redes neuronales convolucionales y técnicas de optimización estadística en entornos gráficos, con el objetivo de avanzar en la mejora de la eficiencia y precisión en la computación gráfica y la inteligencia artificial.*

7. Plan de Trabajo

Las etapas y actividades para cumplir con el Trabajo de Titulación y resolver el problema planteado serán los siguientes:

1. INTRODUCCIÓN

- 1.1. Contextualización del problema*
- 1.2. Justificación del estudio*
- 1.3. Objetivo general*
- 1.4. Objetivos específicos*

2. MARCO TEÓRICO

- 2.1. Fundamentos del Deep Learning*
- 2.2. Aprendizaje por Refuerzo*
- 2.3. Redes Neuronales Convolucionales (CNN)*
 - 2.3.1. Arquitectura y funcionamiento*
 - 2.3.2. Aplicaciones en visión por computadora*
 - 2.3.2. Aplicaciones en entornos gráficos*

3. METODOLOGÍA

- 4.1.1. Selección de la plataforma de desarrollo*
- 4.1.2. Definición de las tareas y actividades del entorno*
- 4.2. Implementación de la red CNN y el agente Q-learning*
 - 4.2.1. Elección de la arquitectura de la red*
 - 4.2.2. Preprocesamiento de datos y entrenamiento del modelo*
- 4.3. Integración de la red CNN al agente Q-learning*
 - 4.3.1. Interacción del agente con la red CNN y el entorno gráfico*

4. RESULTADOS

- 5.1. Evaluación del rendimiento del modelo CNN*



5.2. Análisis del aprendizaje del agente q-learning en el entorno gráfico

5. DISCUSIÓN

6.1. Interpretación de los resultados obtenidos

6.2. Limitaciones y posibles mejoras

6.3. Implicaciones prácticas y teóricas

6. CONCLUSIONES

7.1. Recapitulación de los hallazgos principales

7.2. Contribuciones al campo y áreas de futuro desarrollo

7. REFERENCIAS

8. ANEXOS

9.1. Código fuente utilizado

9.2. Ejemplos de entrada y salida del modelo

8. Bibliografía

- [1] Sutton, R. S., & Barto, A. G. (1998). *Reinforcement Learning: An Introduction*. MIT Press.
- [2] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction*. MIT press
- [3] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press
- [4] Chollet, F. (2017). *Deep learning with python*. Manning Publications
- [5] Botvinick, M., Ritter, S., Wang, J. X., Kurth-Nelson, Z., Blundell, C., & Hassabis, D. (2019). Reinforcement learning, fast and slow. *Trends in Cognitive Sciences*, 23 (5), 408–422
- [6] Artículo de CNN (como ejemplo de una fuente de noticias, no específicamente sobre CNN como tema de estudio): Carey, B. (2019, March 22). *Can we get better at forgetting?* The New York Times
- [7] Biblioteca PyQlearning. (2024). PyQlearning 1.2.7. Python Package Index.
- [8] Watkins, C. J. C. H. (1989). *Learning from Delayed Rewards*. University of Cambridge.Lahiri, S. N., (2003).
- [9] Watkins, C. J. C. H., & Dayan, P. (1992). *Q-learning*. *Machine Learning*, 8(3-4), 279–292
- [10] LeCun, Y., Bengio, Y., & Hinton, G. (2015). *Deep learning*. *Nature*, 521(7553), 436–444
- [11] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction*. MIT Press
- [12] Li, Y. (2017). *Deep Reinforcement Learning: An Overview*
- [13] Yannakakis, G. N., & Togelius, J. (2018). *Artificial Intelligence and Games*. Springer



[14] Roderick, M., MacGlashan, J., & Tellex, S. (2017). *Implementing the Deep Q-Network*.

[14] Yozgatligil, C., Purutcuoglu, V., Yazici, C. y Batmaz, I. (2011). *Validez de las pruebas de homogeneidad para datos de series de tiempo meteorológicas: un estudio de simulación*,

9. Cronograma

Los tiempos de ejecución para cada etapa se muestran en la siguiente tabla.

Actividades	2024																							
	semanas																							
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24
MARCO TEÓRICO																								
METODOLOGÍA																								
RESULTADOS Y DISCUSIONES																								
INTRODUCCIÓN																								
INDICE DE GRÁFICOS Y TABLAS																								

Firma

Geoconda Dennisse Molina Morales
PROPONENTE

Email: geoconda.molina@epn.edu.ec
Telf.: 0983250868

Firma

Ménthor Oswaldo Urvina Mayorga
DIRECTOR

Email: menthor.urvina@epn.edu.ec
Telf.: 0999713593